



Báo cáo tuần 21–24/07/2026

Tóm tắt điều hành

Long-horizon manipulation không phải một lỗi đơn lẻ. Ba nhóm paper trong thư mục `docs/_archive/research_finding/long-horizon/` can thiệp vào ba failure mode khác nhau:

Nhóm	Paper trọng tâm	Câu hỏi được giải quyết	Can thiệp chính
Future prediction	Seer	Action hiện tại có dẫn tới trạng thái tương lai phù hợp không?	Dự đoán latent thị giác tương lai rồi dùng latent đó để điều kiện inverse dynamics.
Hierarchical agent	Hi Robot	Ở thời điểm này robot nên thực hiện subtask nào?	VLM tăng cao chuyển prompt mở và feedback thành lệnh nguyên tử cho VLA tầng thấp.
Memory module	MemoryVLA	Robot đã làm gì và đang ở giai đoạn nào của task?	Memory bank tri giác–nhận thức truy hồi lịch sử và điều kiện action expert.



****Kết luận chính:**** hierarchy, memory và future prediction là ba năng lực trực giao. Một policy có thể biết bước kế tiếp nhưng quên các bước đã làm; có memory nhưng không biết phân rã lệnh dài; hoặc có cả hai nhưng vẫn chọn action ngắn hạn không dẫn tới trạng thái mong muốn.

Phạm vi và nguồn

Báo cáo chỉ tập trung một paper đại diện cho mỗi nhóm theo yêu cầu. LingBot-VA được dùng như phần bổ sung cho Seer, không phải paper đại diện thứ tư.

- Future prediction: [report Seer](#)
- Bổ sung future prediction: [report LingBot-VA](#)
- Hierarchical agent: [report Hi Robot](#)
- Memory module: [report MemoryVLA](#)

Cách tìm và định nghĩa một paper là SOTA



Đây là ****định nghĩa vận hành dùng trong workspace**** để sàng lọc paper đáng đọc và đáng đưa vào báo cáo. “SOTA” ở đây không chỉ có nghĩa là đạt một con số cao nhất trên một bảng riêng lẻ, mà phải có ảnh hưởng, khả năng kiểm chứng và đối chứng đủ mạnh.

1. Citation và mức độ ảnh hưởng

- Ưu tiên paper có **trên 100 citation**. Đây là dấu hiệu cộng đồng đã đọc, sử dụng hoặc đối chiếu kết quả của paper.

- Với paper rất mới, đặc biệt paper năm **2026**, ngưỡng citation có thể được hạ vừa phải vì chưa có đủ thời gian tích lũy trích dẫn.
- Khi nói ngưỡng cho paper mới, hai tiêu chí còn lại — code và chất lượng benchmark — phải được xem xét chặt hơn. Citation thấp vì paper mới khác với citation thấp vì ít ảnh hưởng.

2. Source code và khả năng kiểm chứng

- Ưu tiên paper có **source code công khai**.
- Code càng đầy đủ càng có giá trị: kiến trúc model, training loop, config, data preprocessing, checkpoint, script evaluation và hướng dẫn tái lập.
- Chỉ có inference demo hoặc một repository tối giản được đánh giá thấp hơn code đủ để train và benchmark.
- Có thể chấp nhận ngoại lệ không có code hoặc code chưa đầy đủ nếu paper có mức ảnh hưởng đặc biệt lớn, thể hiện qua citation cao — ví dụ **Hi Robot - 206 citation**.

3. Chất lượng benchmark và baseline

- Paper phải được đánh giá trên benchmark được cộng đồng sử dụng rộng rãi hoặc setting robot thật đủ rõ ràng.
- Baseline nên gồm các model SOTA đã được công nhận như **$\pi 0^*$** , **$\pi 0.5$** hoặc những model mạnh tương đương trong đúng nhóm bài toán.
- Không xem một paper là SOTA chỉ vì nó vượt một vài model lẻ tẻ, ít được biết đến hoặc baseline yếu.
- Khi các paper dùng robot, dữ liệu, horizon và protocol khác nhau, không so trực tiếp success rate như thể chúng thuộc cùng một leaderboard.

✓

****Nguyên tắc kết luận:**** ba tiêu chí được dùng kết hợp, không dùng như ba checkbox độc lập. Một paper đáng gọi là SOTA phải có bằng chứng mạnh về ảnh hưởng, khả năng kiểm chứng và đối chứng với baseline chuẩn; mọi ngoại lệ cần được ghi rõ trong báo cáo.


Dataset và benchmark liên quan tới long-horizon

Benchmark	Thông số chính	Giá trị cho long-horizon
CALVIN	4 environment A–D; 34 subtask; khoảng 24 giờ play data, 2.4M interaction step và 20K language directive.	Protocol LH-MTLC gồm 1,000 chuỗi hợp lệ, mỗi chuỗi 5 instruction liên tiếp. Phù hợp nhất để đo chuyển tiếp giữa subgoal, closed-loop recovery và memory theo tiến trình.
VLABench	100 task category, gồm 60 primitive và 40 composite task; hơn 2,000 object; đánh giá 6 nhóm năng lực.	40 composite task yêu cầu multi-step reasoning, world knowledge và hiểu instruction hàm ý. Phù hợp để đo hierarchical planning kiểu Hi Robot hơn là chỉ độ chính xác motor.

1. Future prediction — Seer

Nguồn: [report Seer](#)

Paper gốc — *Predictive Inverse Dynamics Models are Scalable Learners for Robotic Manipulation*: [arXiv](#) · [PDF](#) trong [GitHub](#)



Kiến trúc Seer: latent foresight điều kiện inverse dynamics

1.1 Finding cốt lõi

Seer cho thấy dự đoán tương lai chỉ hữu ích cho control khi nó nằm trực tiếp trên đường sinh action. Model không đơn thuần học dự đoán ảnh tương lai như một auxiliary task. Nó tạo một latent foresight và cho inverse-dynamics head truy cập latent này để dự đoán action chunk.

Hai readout token tạo luồng nhân quả rõ ràng:

- [FRS] đọc goal, ảnh và state lịch sử để dự đoán trạng thái thị giác ở $(t+n)$.
- [INV] đọc toàn bộ context trên và thêm [FRS] để sinh chuỗi action từ (t) đến $(t+n-1)$.
- Attention là một chiều: [INV] thấy [FRS], nhưng [FRS] không thấy [INV].

Fusion diễn ra trong latent space, trước khi decode ảnh. Vì vậy action loss có thể truyền gradient ngược qua foresight branch và buộc dự đoán tương lai học đặc trưng hữu ích cho điều khiển.

1.2 Vì sao cơ chế này hỗ trợ horizon dài hơn

Một behavioral-cloning policy thông thường ánh xạ quan sát hiện tại trực tiếp sang action. Nó dễ chọn action hợp lý cục bộ nhưng không bảo đảm action đó đưa hệ tới trạng thái trung gian phù hợp với goal.

Seer chèn một “cầu nối”:

$$((g, h_t) \rightarrow \hat{o}^{t+n} \rightarrow a)$$

Nhờ vậy, action chunk được neo vào một kết quả tương lai cụ thể. Đây là planning ngắn trong latent, không phải hierarchical planning toàn task. Horizon của Seer vẫn là khoảng nhìn trước (n) và chuỗi task benchmark; nó không tự phân rã một lệnh 10–15 phút thành nhiều subtask ngữ nghĩa.

1.3 Evidence quan trọng nhất

- Trên LIBERO-LONG, Seer đạt 87.7% success, so với 78.7% khi train from scratch và 77.3% của MPI.
- Trên CALVIN ABC-D, Seer-Large đạt average sequence length 4.28.
- Ablation trên CALVIN cho thấy thêm foresight loss đơn thuần chỉ tăng 3.31 $\rightarrow$ 3.41, còn cho inverse dynamics sử dụng foresight tăng tiếp lên 3.64. Giá trị chủ yếu đến từ **conditioning action bằng tương lai dự đoán**, không chỉ từ regularization.
- Pretraining vẫn có ích với play data thiếu language label: robot state tương lai có thể được dùng làm goal thay thế.

1.4 Giá trị thực dụng

Seer là lựa chọn dễ tiếp cận nhất trong ba hướng:

- 65M tham số trainable ở bản cơ sở;
- có code công khai;
- không bắt buộc nhấn subtask;
- có thể tận dụng play data hoặc robot data có language không đầy đủ.

Hai ý tưởng có thể tách ra thử nghiệm độc lập là dùng state tương lai thay language khi nhấn thiếu, và thay pixel reconstruction bằng latent prediction để giảm chi phí decoder.

1.5 Giới hạn cần giữ trong kết luận

- Paper không sweep khoảng nhìn trước (n), dù đây là hyperparameter quyết định foresight có ý nghĩa hay không.
- Pixel-level MSE có thể tạo dự đoán mờ trong môi trường đa mode; paper không đo chất lượng dự đoán ảnh.
- “Long horizon” trong Seer là LIBERO-LONG và CALVIN sequence tối đa 5 task, không đồng nghĩa task gia đình kéo dài 10–15 phút.
- Seer chỉ nhìn một cửa sổ lịch sử cố định; nó không có episodic memory và không thay thế hierarchy.

1.6 LingBot-VA như hướng mở rộng

Nguồn bổ sung: [report LingBot-VA](#)

Paper gốc — *Causal World Modeling for Robot Control*: [arXiv](#) · [PDF trong GitHub](#)

LingBot-VA đẩy cùng trực giác “tưởng tượng trước rồi hành động” lên quy mô world model:

- video token và action token được đan xen trong một chuỗi autoregressive nhân quả;
- video dynamics và action dynamics có transformer stream riêng nhưng trao đổi qua cross-modal attention;
- KV-cache giữ lịch sử dài ở inference;
- partial denoising cho thấy action không cần video được khử nhiễu hoàn toàn;
- FDM grounding dùng quan sát thật để neo lại dự báo trong async inference, tránh model tiếp tục ảo giác từ rollout cũ.

Bằng chứng nổi bật nhất không chỉ là điểm benchmark mà là failure của naive async: ở RoboTwin horizon 3, cấu hình này giảm còn 32.9 so với 93.2 của cấu hình tham chiếu. Điều này cho thấy world model dùng trong closed-loop control phải được tái căn chỉnh liên tục bằng feedback thật.

LingBot-VA mạnh hơn về world modeling và memory qua causal history, nhưng có quy mô 5.3B, pretrain khoảng 1.4T token trên 16K giờ dữ liệu. Vì vậy Seer phù hợp hơn làm baseline nghiên cứu; LingBot-VA phù hợp để rút ra nguyên tắc thiết kế hoặc thử checkpoint công khai.

2. Hierarchical agent — Hi Robot

Nguồn: [report Hi Robot](#)

Paper gốc — *Hi Robot: Open-Ended Instruction Following with Hierarchical Vision-Language-Action Models*: [arXiv](#) · [PDF trong GitHub](#)

 Hi Robot: VLM tầng cao chuyển prompt mở và feedback thành lệnh cho VLA tầng thấp

Hi Robot: VLM tầng cao chuyển prompt mở và feedback thành lệnh cho VLA tầng thấp

2.1 Finding cốt lõi

Hi Robot cho thấy long-horizon instruction following cần tách **lý luận về ý định** khỏi **điều khiển vận động**:

- System 2 / high level nhận ảnh, prompt mở và feedback của người dùng, rồi xuất một lệnh ngôn ngữ nguyên tử.
- System 1 / low level là π_0 VLA, nhận lệnh nguyên tử và sinh action chunk bằng flow matching.
- Tầng cao được gọi lại mỗi một giây hoặc ngay khi người dùng đưa feedback mới.

Giao diện ngôn ngữ giữa hai tầng làm cho planner dễ quan sát và sửa: có thể biết tầng cao đang yêu cầu “nhặt lon” hay “đặt cà chua vào bát”, thay vì truyền một latent không diễn giải được.

2.2 Finding quan trọng hơn kiến trúc: dữ liệu situated tổng hợp

Hi Robot không có năng lực open-ended chỉ vì ghép hai model. Thành phần tạo năng lực chính là pipeline sinh dữ liệu tổng hợp có định vị theo quan sát và tiến trình task.

Từ demo teleoperation, hệ thống cắt các skill 1–3 giây và gán nhãn primitive. Một VLM lớn sau đó sinh ngược:

- prompt ban đầu;
- correction giữa chừng;
- constraint phủ định hoặc cụ thể;
- utterance phản hồi của robot.

Việc generator được condition trên chuỗi skill đã xây ra giúp prompt tổng hợp nhất quán với trạng thái task. Ablation cho thấy bỏ synthetic data làm giảm mạnh cả Instruction Accuracy và Task Progress; dùng cùng dữ liệu nhưng bỏ hierarchy cũng giảm đáng kể. Nghĩa là **dữ liệu và kiến trúc đều đóng góp**, và không nên gán toàn bộ cải thiện cho hệ hai tầng.

2.3 Vì sao cơ chế này hỗ trợ horizon dài hơn

Một flat VLA phải giữ constraint ngôn ngữ, hiểu feedback mới, quyết định subtask và điều khiển motor trong cùng một policy call. Hi Robot giao việc “chọn bước kế tiếp” cho tầng cao và thu hẹp bài toán tầng thấp về một skill ngắn.

Hierarchy đặc biệt phù hợp khi:

- lệnh chứa nhiều mục tiêu hoặc constraint;
- người dùng thay đổi yêu cầu giữa chừng;
- trạng thái môi trường đòi hỏi re-plan;
- cần output ngôn ngữ để kiểm tra reasoning.

Đây là semantic horizon, khác với temporal memory. Tầng cao có thể chọn đúng subtask nhưng vẫn lặp lại một bước nếu không nhớ lịch sử đủ dài.

2.4 Evidence và giới hạn

Evidence được báo cáo trên ba embodiment thật, với hai metric tách riêng chất lượng lệnh tầng cao và tiến độ thi hành. Hi Robot vượt flat VLA và tầng cao GPT-4o trong setting của paper; human high-level oracle cho thấy khi lệnh nguyên tử đúng, tầng thấp thường thực hiện tốt.

Các giới hạn quan trọng:

- tầng cao không có long-term memory;
- hai tầng train tách rời và không biết năng lực hoặc trạng thái nội bộ của nhau;
- không có detector rõ ràng cho “subtask đã hoàn thành”, chỉ gọi lại theo lịch;
- mỗi task có pipeline dữ liệu tổng hợp riêng, chưa chứng minh một high-level model hợp nhất đa task;
- không có đối chứng trực tiếp với kiến trúc một-model như $\pi 0.5$.
- Hiện tại không có **codebase** để kiểm chứng mô hình này.

3. Memory module — MemoryVLA

Nguồn: [report MemoryVLA](#)

Paper gốc — *MemoryVLA: Perceptual-Cognitive Memory in Vision-Language-Action Models for Robotic Manipulation*: [arXiv](#) · [PDF trong GitHub](#)



MemoryVLA: kiến trúc Cognition–Memory–Action với Perceptual-Cognitive Memory Bank

MemoryVLA: kiến trúc Cognition–Memory–Action với Perceptual-Cognitive Memory Bank

3.1 Finding cốt lõi

MemoryVLA bắt đầu từ quan sát rằng manipulation có tính non-Markovian: hai frame hiện tại gần như giống nhau vẫn có thể cần action khác nhau, tùy robot đã làm gì trước đó. Ví dụ, sau khi nhấn một nút, ảnh có thể không thay đổi đủ rõ để policy single-frame biết nút đó đã được xử lý.

Thay vì nối nhiều frame vào VLM, MemoryVLA lưu hai loại biểu diễn:

- **Perceptual memory**: 256 token mỗi observation, giữ chi tiết thị giác.
- **Cognitive memory**: một EOS token từ LLaMA-7B, tóm tắt ngữ nghĩa ảnh + instruction.

Current observation query hai bank riêng, kết quả retrieval được trộn với current feature bằng learned gate, rồi dùng để điều kiện DiT action expert.

3.2 Retrieval, fusion và consolidation

Mỗi memory key nhận timestep embedding, còn value giữ feature gốc. Timestep giúp attention phân biệt một trạng thái xuất hiện sớm hay muộn.

Khi memory vượt capacity, hệ thống không bỏ entry cũ nhất theo FIFO. Nó tìm cặp entry kề nhau giống nhất theo cosine similarity, average hai feature và giữ timestamp của entry đầu. Ý tưởng là nén các đoạn tĩnh/lặp và giữ những mốc thay đổi.

Điều quan trọng khi hiểu implementation:

- một entry được thêm sau mỗi policy call, không phải sau từng action trong chunk;
- past feature được detach, nên gradient không truyền xuyên toàn episode;
- perceptual và cognitive bank consolidate độc lập;
- merge là heuristic 50/50, không count-weighted và không học được;
- PCMB là fixed-capacity temporal compression, không phải episodic database chính xác.

3.3 Vì sao cơ chế này hỗ trợ horizon dài hơn

MemoryVLA không tạo subtask mới và cũng không dự đoán goal tương lai. Nó giảm state aliasing: current frame được diễn giải cùng với bằng chứng về các sự kiện trước đó.

Điều này đặc biệt phù hợp với task cần:

- đếm số lần đã thao tác;
- nhớ vật đã đặt ở đâu;
- giữ thứ tự pick/place;
- tránh lặp lại bước đã hoàn thành;
- suy ra trạng thái ẩn không thể thấy từ frame hiện tại.

3.4 Evidence quan trọng nhất

- Trên real-world general task, MemoryVLA đạt 85 so với 76 của CogACT; chênh +9.
- Trên nhóm long-horizon temporal, MemoryVLA đạt 83 so với 57 của CogACT; chênh +26.
- Mức tăng lớn ở Seq. Push Buttons (+43) và các task cần nhớ vị trí/thứ tự, phù hợp với cơ chế được đề xuất.
- Ablation cho thấy dùng cả perceptual và cognitive memory đạt 71.9, cao hơn từng stream riêng; learned gate và token merge đều tốt hơn add/FIFO.

Dấu hiệu cảnh báo là memory dài hơn không luôn tốt hơn: (L=16) đạt 71.9 nhưng (L=64) giảm còn 67.7. Capacity lớn có thể đưa thêm distractor vào retrieval hoặc làm lộ giới hạn của consolidation.

3.5 Giá trị thực dụng và giới hạn

MemoryVLA có yêu cầu input tương đối nhẹ: một RGB third-person, instruction và action target; không bắt buộc wrist camera, depth, proprioception hay nhãn subtask. PCMB cũng có thể gán về nguyên tắc vào một action expert khác.

Tuy nhiên, model nền vẫn lớn và full-finetune nhiều thành phần. Memory consolidation hiện là heuristic; timestamp sau merge chỉ còn xấp xỉ; hai memory stream có thể mất alignment theo thời gian; và paper chưa so trực tiếp memory với hierarchical planner trên cùng benchmark temporal.

4. So sánh và finding tổng hợp

Thuộc tính	Seer	Hi Robot	MemoryVLA
Đơn vị mở rộng horizon	Future state + action chunk	Chuỗi subtask ngôn ngữ	Lịch sử observation/policy call
Giải quyết trực tiếp	Myopic action	Task decomposition và feedback	State aliasing và quên tiến trình
Nhân bổ sung	Không bắt buộc subtask; có thể dùng future state làm goal	Cần skill segmentation và synthetic situated prompts	Không cần nhân mới ngoài episode có thứ tự
Không giải quyết tốt	Task-level planning và memory dài	Long-term memory và trạng thái nội bộ tăng thấp	Semantic planning và future feasibility
Chi phí/khả năng thử nghiệm	Nhẹ nhất, baseline hợp lý	Cần hai model và pipeline dữ liệu	Model lớn nhưng module rõ và code công khai

4.1 Ba kết luận có thể giữ lại

- Long horizon nên được phân loại theo failure mode trước khi chọn model.** Nếu robot lặp lại bước cũ, thêm foresight chưa chắc giúp; nếu robot nhớ đầy đủ nhưng không hiểu constraint, memory cũng chưa đủ.
- Hierarchy và memory bổ sung nhau.** Hi Robot tự nêu thiếu memory; MemoryVLA không có task planner. Một hệ mạnh cần high level quyết định subtask và memory xác định tiến độ.
- Future prediction hữu ích nhất khi gắn vào action path và grounded bằng feedback thật.** Seer chứng minh lợi ích của latent foresight conditioning; LingBot-VA cho thấy async rollout không grounded có thể sụp đổ mạnh ở horizon dài.

4.2 Kiến trúc kết hợp có thể kiểm chứng

 ****Suy luận từ các report, chưa được paper nào kiểm chứng end-to-end:**** dùng Hi Robot ở tầng task để sinh subtask; dùng PCMB của MemoryVLA để giữ tiến trình và trạng thái ẩn; dùng Seer-style foresight ở low-level policy để sinh action chunk hướng tới trạng thái trung gian.

Luồng khái niệm:

- High-level VLM đọc prompt, observation và memory summary để chọn subtask.
- Low-level policy truy hồi perceptual/cognitive memory.
- Foresight branch dự đoán latent trạng thái sau (n) bước dưới subtask hiện tại.
- Inverse dynamics sinh action chunk có điều kiện trên latent tương lai.
- Sau execution, observation thật cập nhật memory và kích hoạt re-plan khi cần.

Điểm quan trọng là observation thật phải đóng vòng điều khiển. Không nên để hierarchy hoặc world model tiếp tục dựa trên trạng thái tự dự đoán mà không groundings.

Kết luận

Seer, Hi Robot và MemoryVLA đại diện cho ba cách kéo dài năng lực VLA ở ba tầng khác nhau:

- **Seer:** nhìn trước để action ngắn hạn có hướng.
- **Hi Robot:** chia mục tiêu mở thành các bước có thể thực thi và tiếp nhận feedback.
- **MemoryVLA:** giữ dấu vết tiến trình để cùng một quan sát không bị hiểu sai trạng thái.

Không paper nào chứng minh một cơ chế đơn lẻ giải quyết toàn bộ long-horizon manipulation. Finding mạnh nhất từ tập report là cần đánh giá riêng ba trục: **task decomposition, temporal memory và future-grounded control**; sau đó mới kết hợp theo failure mode thực tế.